

---

# Восстановление траектории движения руки по видео

---

Владимиров Эдуард  
vladimirov.ea@phystech.edu

Исаченко Роман  
isa-ro@yandex.ru

Курдюкова Антонина  
kurdiukova.ad@phystech.edu

6 марта 2022 г.

## Аннотация

Решается задача прогнозирования временного ряда со сложной структурой. Под сложной структурой понимается наличие зависимостей и варьирующийся период. Требуется найти причинно-следственные связи между рядами и снизить размерность траекторных пространств. В работе показано, что методы канонического корреляционного анализа, такие как метод главных компонент, метод частичных наименьших квадратов и другие, являются частным случаем метода перекрестных отображений Сугихары. Для демонстрации результатов работы используется траектория движения руки, восстановленная по видео, и сигнал акселерометра.

Ключевые слова: временной ряд · фазовая траектория · траекторное подпространство · сходящееся перекрёстное отображение · частичные наименьшие квадраты · канонический корреляционный анализ

## 1 Введение

В данной работе решается задача прогнозирования временного ряда на основе других рядов. Одна из трудностей задачи заключается в обнаружении связи между рядами и исключении несвязанных рядов из прогностической модели. Решение этой проблемы повышает качество прогноза.

В данной работе применяется метод сходящегося перекрёстного отображения (convergent cross mapping, CCM) [1, 2], который эффективен для рядов, порождённых динамической системой. Он основан на сравнении ближайших соседей в траекторном пространстве ряда  $\mathbf{x}$ , полученных с помощью ряда  $\mathbf{y}$ .

При построении прогностической модели используется траекторная матрица (или матрица сдвига), описывающая фазовое пространство временного ряда. Например, в методе анализа спектральных компонент (singular spectrum analysis, SSA) [3, 4, 5] прогноз временного ряда основан на спектральном разложении ковариационной матрицы,

полученной по траекторной. В ССМ матрицы сдвига используются для проверки наличия липшицева отображения между траекторными пространствами.

Однако размерность траекторного пространства может оказаться чрезмерно высокой, что приводит к неустойчивости прогностической модели. В таком случае необходимо снизить размерность траекторного пространства путём построения проекции фазовой траектории в некоторое подпространство. Для ССМ нет конкретного способа выбрать подпространство, в котором аппроксимируется фазовая траектория. В работе [6] эта проблема решается с помощью сферической регрессии. Согласно этому методу, информация об искомом подпространстве извлекается из множества эмпирических направлений  $\{\mathbf{x}_i - \mathbf{x}_j \mid i < j\}$ . В работе [7] используется автоматический выбор пары главных компонент. Идея заключается в сравнении спектральных плотностей главных компонент. Также используется простой перебор по главным компонентам [8].

Метод проекции в латентное пространство (partial least squares, PLS) [9, 10] отбирает наиболее значимые признаки и строит новые как их линейные комбинации. Это позволяет получить простую, точную и устойчивую прогностическую модель. Наряду с PLS используется метод канонического анализа корреляции (ССА) [11]. Он похож на PLS за исключением того, что первый метод максимизирует ковариацию, а последний — корреляцию. Недостатком этих моделей является их низкая точность при оценивании нелинейных зависимостей между данными. Разработаны нелинейные модели PLS[12, 13] и ССА[14, 15]. В данной статье используется модель NNPLS [16], которая преобразует исходные данные с помощью нейронной сети.

В теоретической части работы показано, что ССА и PLS являются частными случаями ССМ.

В качестве модели для предсказания временного ряда по набору рядов используется алгоритм многомерной гусеницы [3], являющийся обобщением на многомерный случай алгоритма SSA

Эксперимент проводится на наборе вручную собранных данных. Он представляет собой совокупность ключевых точек, полученных по видео движения человека, а также показания акселерометра и гироскопа, снятые с руки человека. В эксперименте строится прогноз рядов, использующий обнаруженные связанные компоненты рядов

## 2 Постановка задачи

Пусть значения исходного временного ряда  $\mathbf{x}(t)$  доступны в моменты времени  $t = 1, 2, \dots, n$ . Предполагается, что на значения  $\mathbf{x}(t)$  оказывает влияние набор внешних факторов  $\mathbf{y}_1(t), \dots, \mathbf{y}_m(t)$

В момент прогноза  $n$  необходимо определить будущие значения исходного процесса  $\mathbf{x}(t)$  в моменты времени  $n + 1, \dots, n + p$ , учитывая влияние внешних факторов  $\mathbf{y}_1(t), \dots, \mathbf{y}_m(t)$ . При этом считаем, что значения внешних факторов в моменты времени  $\mathbf{y}_1(n + 1), \dots, \mathbf{y}_1(n + p), \dots, \mathbf{y}_m(n + 1), \dots, \mathbf{y}_m(n + p)$  являются доступными.

Для вычисления будущих значений временного ряда требуется определить функциональную зависимость, отражающую связь между прошлыми значениями  $\mathbf{x}$  и будущими, а также принимающую во внимание влияние внешних факторов  $\mathbf{y}_1, \dots, \mathbf{y}_m$ .

$$\mathbf{x}(t) = F(\mathbf{x}(t-1), \dots, \mathbf{y}_1(t), \mathbf{y}_1(t-1), \dots, \mathbf{y}_m(t), \mathbf{y}_m(t-1), \dots) + \varepsilon_t \quad (1)$$

Зависимость (1) называется моделью прогнозирования с учётом внешних факторов. Требуется создать такую модель, для которой среднее квадратичное отклонение истинного значения от прогнозируемого стремится к минимальному для заданного  $p$ .

$$\hat{E} = \frac{1}{p} \sum_{i=n+1}^{n+p} \varepsilon_i^2 \rightarrow \min \quad (2)$$

## 2.1 Метод ССМ

Зададим для временного ряда  $\mathbf{x} = [x_1, \dots, x_n]$  его траекторную матрицу следующим образом:

$$\mathbf{H}_{\mathbf{x}} = \begin{bmatrix} x_1 & x_2 & \dots & x_\tau \\ x_2 & x_3 & \dots & x_{\tau+1} \\ \vdots & \vdots & \ddots & \vdots \\ x_N & x_{N+1} & \dots & x_n \end{bmatrix},$$

где  $N$  — число задержек,  $\tau = n - N + 1$

Обозначим  $i$ -ый столбец матрицы  $\mathbf{H}_{\mathbf{x}}$  как  $\mathbf{x}_i$ . Тогда матрица  $\mathbf{H}_{\mathbf{x}}$  примет вид:

$$\mathbf{H}_{\mathbf{x}} = [\mathbf{x}_1, \dots, \mathbf{x}_\tau], \quad \mathbf{x}_i = [x_i, x_{i+1}, \dots, x_{i+N-1}]^\top$$

Заметим, что все векторы  $\mathbf{x}_t$  принадлежат  $N$ -мерному траекторному пространству  $\mathbb{H}_{\mathbf{x}} \subseteq \mathbb{R}^N$  ряда  $\mathbf{x}$  и образуют фазовую траекторию  $\mathbf{x}(t) \in \mathbb{R}^N$ .

Обнаружение зависимости между рядами  $\mathbf{x}$  и  $\mathbf{z}$  осуществляется следующим образом. Выберем момент  $t_0 \in \{1, \dots, \tau\}$  и найдём  $k$  ближайших соседей  $\mathbf{x}_{t_0}$  в  $\mathbb{H}_{\mathbf{x}}$ . Обозначим их множество как  $U_k(\mathbf{x}_{t_0}) = \{\mathbf{x}_{t_1}, \dots, \mathbf{x}_{t_k}\}$ .

Так как оба ряда определены на одной временной оси, найдём  $U_k(\mathbf{z}_{t_0})$  в пространстве  $\mathbb{H}_{\mathbf{z}}$ , проделав все вышеприведённые операции. Определим отображение из  $U_k(\mathbf{x}_{t_0})$  в  $U_k(\mathbf{z}_{t_0})$  следующим образом:

$$\varphi : \mathbf{x}_{t_i} \rightarrow \mathbf{z}_{t_i}, \quad i = 1, \dots, k$$

. Утверждается, что ряды  $\mathbf{x}$  и  $\mathbf{z}$  связаны, если отображение  $\varphi$  является липшицевым.

$$\rho_{\mathbb{H}_{\mathbf{z}}}(\varphi(\mathbf{x}_i), \varphi(\mathbf{x}_j)) \leq n \rho_{\mathbb{H}_{\mathbf{x}}}(\mathbf{x}_i, \mathbf{x}_j) \quad \forall \mathbf{x}_i, \mathbf{x}_j \in \mathbb{H}_{\mathbf{x}}$$

Проверим наличие такого отображения следующим образом. Введём меру близости векторов в окрестностях  $U_k(\mathbf{x}_{t_0})$  и  $U_k(\mathbf{z}_{t_0})$ :

$$L(\mathbf{x}, \mathbf{z}) = \frac{R(U_k(\mathbf{x}_{t_0}))}{R(U_k(\mathbf{z}_{t_0}))}, \quad R(U_k(\mathbf{x}_{t_0})) = \frac{1}{k} \sum_{i=1}^k \rho_{\mathbb{H}_x}(\mathbf{x}_{t_0}, \mathbf{x}_{t_i}) \quad (3)$$

Если  $L(x, z)$  больше некоторого порога  $C(n)$ , то ряд  $\mathbf{z}$  зависит от ряда  $\mathbf{x}$

Прогноз  $\hat{x}_t$  первого элемента вектора  $\mathbf{x}$  строится следующим образом:

$$\hat{x}_t = \sum_{i=1}^k w_i x_{t_i}, \quad w_i = \frac{u_i}{\sum_{j=1}^k u_j}, \quad u_i = \exp(-\|\mathbf{x}_t - \mathbf{x}_{t_i}\|),$$

где  $x_{t_i}$  — первые компоненты ближайших соседей  $\mathbf{x}_t$

## 2.2 Метод PLS

Метод частичных наименьших квадратов восстанавливает связь между наборами данных  $\mathbf{X}$  и  $\mathbf{Y}$ . Матрицы объектов  $\mathbf{X}$  и целевая матрица  $\mathbf{Y}$  проецируются на латентное пространство  $\mathbb{R}^l$  меньшей размерности следующим образом:

$$\begin{aligned} \mathbf{X}_{n \times m} &= \mathbf{T}_{n \times l} \cdot \mathbf{P}_{l \times m}^T + \mathbf{E}_{n \times m} \\ \mathbf{Y}_{n \times k} &= \mathbf{U}_{n \times l} \cdot \mathbf{Q}_{l \times k}^T + \mathbf{F}_{n \times k}, \end{aligned}$$

где  $\mathbf{T}$  и  $\mathbf{U}$  — матрицы описания объектов и исходов в латентном пространстве,  $\mathbf{P}$  и  $\mathbf{Q}$  — матрицы перехода из латентного пространства в исходное,  $\mathbf{E}$  и  $\mathbf{F}$  — матрицы остатков.

Функция преобразования исходных данных имеет вид:

$$f(\mathbf{X}) = \mathbf{X}\mathbf{W}_x \quad g(\mathbf{Y}) = \mathbf{Y}\mathbf{W}_y,$$

где матрицы весов  $\mathbf{W}_x \in \mathbb{R}^{m \times l}$  и  $\mathbf{W}_y \in \mathbb{R}^{k \times l}$  находятся путём максимизации выборочной ковариации:

$$(\mathbf{W}_x, \mathbf{W}_y) = \underset{\mathbf{W}_x, \mathbf{W}_y}{\operatorname{argmax}} \operatorname{Cov}(\mathbf{X}\mathbf{W}_x, \mathbf{Y}\mathbf{W}_y)$$

## 2.3 Метод ССА

Канонический корреляционный анализ находит две матрицы перехода в латентные пространства для  $\mathbf{X}$  и  $\mathbf{Y}$  соответственно, так чтобы коэффициент корреляции между проекциями был максимальным.

$$(\mathbf{w}_{x_1}, \mathbf{w}_{y_1}) = \underset{\mathbf{w}_x, \mathbf{w}_y}{\operatorname{argmax}} \operatorname{Corr}(\mathbf{X}\mathbf{w}_x, \mathbf{Y}\mathbf{w}_y) \quad (4)$$

Первые столбцы матриц весов находятся путём решения данной задачи оптимизации (4). Затем ищутся векторы, максимизирующие ту же корреляцию, но с ограничением, что они не коррелируют с первой парой векторов. Процедура продолжается  $l$  шагов, где  $l$  — размерность латентного пространства.

## 2.4 Алгоритм предсказания

TODO

## Список литературы

- [1] G. Sugihara, B. Grenfell, and R. M. May. Distinguishing error from chaos in ecological time series. *Phil. Trans. Roy. Soc. London B*, 330(1257):235–51, 1990.
- [2] George Sugihara and Robert M May. Nonlinear forecasting as a way of distinguishing chaos from measurement error in time series. *Nature*, 344(6268):734–741, 1990.
- [3] Nina Golyandina and D Stepanov. Ssa-based approaches to analysis and forecast of multidimensional time series. In *proceedings of the 5th St. Petersburg workshop on simulation*, volume 293, page 298. St. Petersburg State University St. Petersburg, Russia, 2005.
- [4] Nina Golyandina, Vladimir Nekrutkin, and Anatoly A Zhigljavsky. *Analysis of time series structure: SSA and related techniques*. CRC press, 2001.
- [5] Anatoly Zhigljavsky. Singular spectrum analysis for time series: Introduction to this special issue. *Statistics and its Interface*, 3(3):255–258, 2010.
- [6] Карина Равилевна Усманова, ЮИ Журавлёв, КВ Рудаков, and ВВ Стрижов. Аппроксимация фазовой траектории квазипериодических сигналов методом сферической регрессии. *Вестник Московского университета. Серия 15: Вычислительная математика и кибернетика*, (4):40–46, 2020.
- [7] Th Alexandrov and N Golyandina. Automatic extraction and forecast of time series cyclic components within the framework of ssa. In *Proceedings of the 5th St. Petersburg Workshop on Simulation*, pages 45–50. St. Petersburg State University St. Petersburg, 2005.
- [8] Карина Равилевна Усманова and Вадим Викторович Стрижов. Модели обнаружения зависимостей во временных рядах в задачах построения прогностических моделей. *Системы и средства информатики*, 29(2):12–30, 2019.
- [9] Roman Rosipal. Nonlinear partial least squares an overview. *Chemoinformatics and advanced machine learning perspectives: complex computational methods and collaborative techniques*, pages 169–189, 2011.
- [10] Roman Rosipal and Nicole Kramer. Overview and recent advances in partial least squares. In *International Statistical and Optimization Perspectives Workshop Subspace, Latent Structure and Feature Selection*, pages 34–51. Springer, 2005.
- [11] David R Hardoon, Sandor Szedmak, and John Shawe-Taylor. Canonical correlation analysis: An overview with application to learning methods. *Neural computation*, 16(12):2639–2664, 2004.
- [12] S Joe Qin and Thomas J McAvoy. Nonlinear pls modeling using neural networks. *Computers & Chemical Engineering*, 16(4):379–391, 1992.
- [13] Hugo Hiden, Ben McKay, Mark Willis, and M Tham. Non-linear partial least squares using genetic programming. *Genetic programming*, pages 128–133, 1998.

- [14] Pei Ling Lai and Colin Fyfe. Kernel and nonlinear canonical correlation analysis. *International Journal of Neural Systems*, 10(05):365–377, 2000.
- [15] Galen Andrew, Raman Arora, Jeff Bilmes, and Karen Livescu. Deep canonical correlation analysis. In *International conference on machine learning*, pages 1247–1255. PMLR, 2013.
- [16] Elif Bulut and Erol Egrioglu. A new partial least square method based on elman neural network. *American Journal of Intelligent Systems*, 4(4):154–158, 2014.