
Восстановление движения руки по видео

Владимиров Эдуард
vladimirov.ea@phystech.edu

Исаченко Роман
isa-ro@yandex.ru

Курдюкова Антонина
kurdiukova.ad@phystech.edu

1 марта 2022 г.

Аннотация

Решается задача прогнозирования временного ряда со сложной структурой. Под сложной структурой понимается наличие зависимостей и варьирующий период. Требуется найти причинно-следственные связи между рядами и снизить размерность траекторных пространств. В работе показано, что методы канонического корреляционного анализа, такие как метод главных компонент, метод частичных наименьших квадратов и другие, являются частным случаем метода перекрестных отображений Сугихары. Для демонстрации результатов работы используется траектория движения руки, восстановленная по видео, и сигнал акселерометра.

Ключевые слова Временной ряд · Фазовая траектория · Траекторное подпространство · Сходящееся перекрёстное отображение · Частичные наименьшие квадраты · Канонический корреляционный анализ

1 Введение

В данной работе решается задача прогнозирования временного ряда на основе других рядов. Одна из трудностей задачи заключается в обнаружении связи между рядами и исключении несвязанных рядов из прогностической модели. Решение этой проблемы повышает качество прогноза.

В данной работе применяется метод сходящегося перекрёстного отображения (ССМ) [12, 13], который эффективен для рядов, порождённых динамической системой. Он основан на сравнении ближайших соседей в траекторном пространстве ряда \mathbf{x} , полученных с помощью ряда \mathbf{y} .

При построении прогностической модели часто используется траекторная матрица (или матрица сдвига), описывающая фазовое пространство временного ряда. Например, в методе анализа спектральных компонент (SSA) [5, 4, 14] прогноз временного ряда основан на спектральном разложении ковариационной матрицы, полученной по траекторной. В ССМ матрицы сдвига используются для проверки наличия липшицева отображения между траекторными пространствами.

Однако размерность траекторного пространства может оказаться чрезмерно высокой, что приводит к неустойчивости прогностической модели. В таком случае необходимо снизить размерность траекторного пространства путём построения проекции фазовой траектории в некоторое подпространство. Для ССМ нет конкретного способа выбрать подпространство, в котором аппроксимируется фазовая траектория. В работе [15] эта процедура осуществляется с помощью сферической регрессии. Согласно этому методу, информация об искомом подпространстве извлекается из множества эмпирических направлений $\{\mathbf{x}_i - \mathbf{x}_j \mid i < j\}$. В работе [1] используется автоматический выбор пары главных компонент. Идея заключается в сравнении спектральных плотностей главных компонент. Также используется простой перебор по главным компонентам [16].

Метод проекции в латентное пространство (partial least squares, PLS) [10, 11] отбирает наиболее значимые признаки и строит новые как их линейные комбинации. Это позволяет получить простую, точную и устойчивую прогностическую модель. Наряду с PLS используется метод канонического анализа корреляции (CCA) [6]. Он похож на PLS за исключением того, что первый метод максимизирует ковариацию, а последний - корреляцию. Недостатком этих моделей является их малая эффективность

при наличии нелинейных зависимостей между данными. Разработаны нелинейные модели PLS[9, 7] и ССА[8, 2]. В данной статье используется модель NNPLS [3], которая преобразует исходные данные с помощью нейронной сети.

В теоретической части работы планируется показать, что ССА и PLS являются частными случаями ССМ.

В качестве модели для предсказания временного ряда по набору рядов используется алгоритм многомерной гусеницы [5], являющийся обобщением на многомерный случай алгоритма SSA

Эксперимент проводится на наборе вручную собранных данных. Он представляет собой совокупность ключевых точек, полученных по видео движения человека, а также показания акселерометра и гироскопа, снятые с руки человека. В эксперименте строится прогноз рядов, использующий обнаруженные связанные компоненты рядов

2 Постановка задачи

Список литературы

- [1] Th Alexandrov and N Golyandina. Automatic extraction and forecast of time series cyclic components within the framework of ssa. In Proceedings of the 5th St. Petersburg Workshop on Simulation, pages 45–50. St. Petersburg State University St. Petersburg, 2005.
- [2] Galen Andrew, Raman Arora, Jeff Bilmes, and Karen Livescu. Deep canonical correlation analysis. In International conference on machine learning, pages 1247–1255. PMLR, 2013.
- [3] Elif Bulut and Erol Egrioglu. A new partial least square method based on elman neural network. American Journal of Intelligent Systems, 4(4):154–158, 2014.
- [4] Nina Golyandina, Vladimir Nekrutkin, and Anatoly A Zhigljavsky. Analysis of time series structure: SSA and related techniques. CRC press, 2001.
- [5] Nina Golyandina and D Stepanov. Ssa-based approaches to analysis and forecast of multidimensional time series. In proceedings of the 5th St. Petersburg workshop on simulation, volume 293, page 298. St. Petersburg State University St. Petersburg, Russia, 2005.
- [6] David R Hardoon, Sandor Szedmak, and John Shawe-Taylor. Canonical correlation analysis: An overview with application to learning methods. Neural computation, 16(12):2639–2664, 2004.
- [7] Hugo Hiden, Ben McKay, Mark Willis, and M Tham. Non-linear partial least squares using genetic programming. Genetic programming, pages 128–133, 1998.
- [8] Pei Ling Lai and Colin Fyfe. Kernel and nonlinear canonical correlation analysis. International Journal of Neural Systems, 10(05):365–377, 2000.
- [9] S Joe Qin and Thomas J McAvoy. Nonlinear pls modeling using neural networks. Computers & Chemical Engineering, 16(4):379–391, 1992.
- [10] Roman Rosipal. Nonlinear partial least squares an overview. Chemoinformatics and advanced machine learning perspectives: complex computational methods and collaborative techniques, pages 169–189, 2011.
- [11] Roman Rosipal and Nicole Kramer. Overview and recent advances in partial least squares. In International Statistical and Optimization Perspectives Workshop Subspace, Latent Structure and Feature Selection, pages 34–51. Springer, 2005.
- [12] G. Sugihara, B. Grenfell, and R. M. May. Distinguishing error from chaos in ecological time series. Phil. Trans. Roy. Soc. London B, 330(1257):235–51, 1990.
- [13] George Sugihara and Robert M May. Nonlinear forecasting as a way of distinguishing chaos from measurement error in time series. Nature, 344(6268):734–741, 1990.
- [14] Anatoly Zhigljavsky. Singular spectrum analysis for time series: Introduction to this special issue. Statistics and its Interface, 3(3):255–258, 2010.
- [15] Карина Равилевна Усманова, ЮИ Журавлёв, КВ Рудаков, and ВВ Стрижов. Аппроксимация фазовой траектории квазипериодических сигналов методом сферической регрессии. Вестник Московского университета. Серия 15: Вычислительная математика и кибернетика, (4):40–46, 2020.

- [16] Карина Равиловна Усманова and Вадим Викторович Стрижов. Модели обнаружения зависимостей во временных рядах в задачах построения прогностических моделей. Системы и средства информатики, 29(2):12–30, 2019.